Taller 1 — Regresión Regularizada en Datos Genómicos

Asignatura: Análisis Avanzado de datos, por el profesor Andrés Nicolás López. **Estudiantes:** Stefany Mojica, Sara Castillejo y Juan Sebastián Rodríguez. *Maestría en Matemáticas Avanzadas y Ciencias de la Computación Universidad del Rosario*

Problema

El conjunto de datos `taller1.txt` contiene el perfil genómico de **1200 líneas celulares** como modelos de cáncer. Se busca determinar cuáles de los **5000 genes** son relevantes para predecir la efectividad del tratamiento anticáncer (variable continua).

NOTA: para correr correctamente este código, se debe agregar manualmente el archivo `taller1.txt` al clonar el repositorio. Dejamos aquí debajo un resumen solo con los resultados para una revisión rápida, pero en el archivo .py está el análisis completo.

Punto 1 — Multicolinealidad

¿Hay multicolinealidad en los datos?

Sí. Las evidencias son:

Indicador	Valor	Interpretación
Dimensionalidad	p=5000 >> n=1200	X'X no es invertible
Rango de X	1200 de 5000	3800 dependencias lineales exactas
Número de condición	2.89	>> 30, multicolinealidad severa
Componentes para 90% varianza	918 de 5000	Alta redundancia entre genes

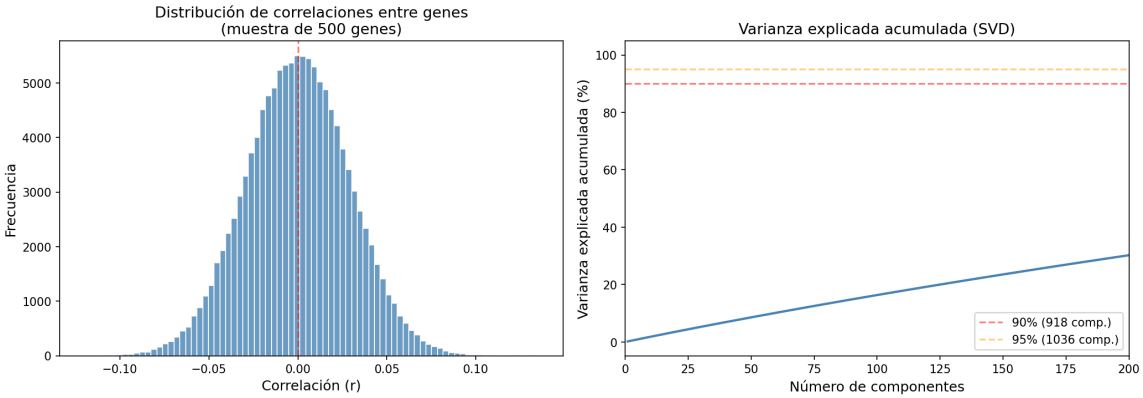

Figure 1: Multicolinealidad

Punto 2 — Partición de datos

Conjunto	Observaciones
Entrenamiento	1000
Prueba	200
Total	**1200**

- Semilla utilizada: `2026`

Punto 3 — Selección de λ por validación cruzada

Método: **10-Fold Cross-Validation** sobre los 1000 datos de entrenamiento.

Método	λ óptimo	ECM (CV)	Genes activos
Ridge	52.140083	17.395507	5000
Lasso	0.070548	1.249969	117

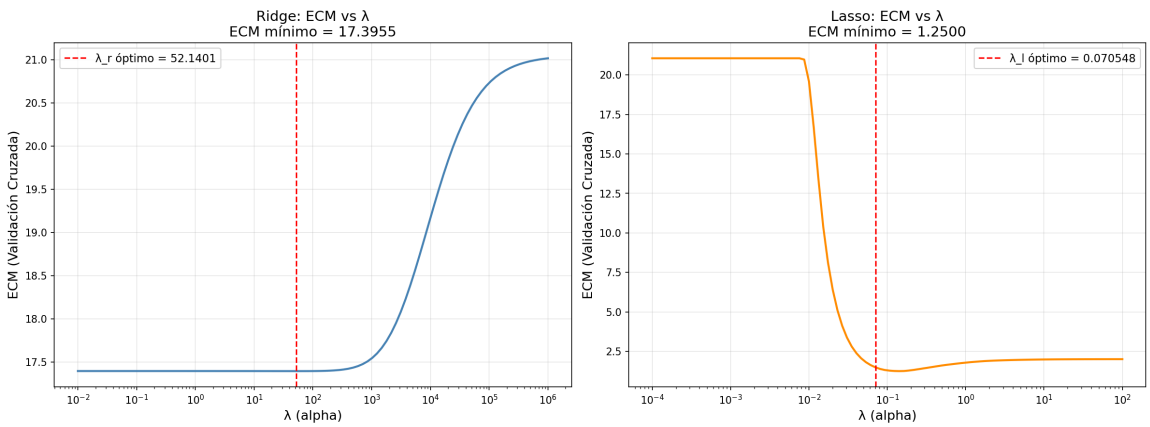

Figure 2: ECM vs Lambda

Punto 4 — Ajuste con λ óptimos

Modelos ajustados sobre los **1000 datos de entrenamiento**.

Métrica	Ridge	Lasso
λ óptimo	52.140083	0.070548
ECM entrenamiento	0.002765	0.929672
Genes activos	5000	117

Punto 5 — Selección del mejor modelo

Criterio: **ECM sobre los 200 datos de prueba** (uso único).

Métrica	Ridge	Lasso
ECM prueba	14.041272	1.153541
Genes activos	5000	117

Modelo seleccionado: Lasso - Redujo el ECM en un **91.78%** respecto a Ridge. - Utilizó solo el **2.34%** de los genes que usa Ridge.

Punto 6 — Reajuste con los 1200 datos

Modelo **Lasso** reajustado sobre las **1200 observaciones** con $\lambda = 0.070548$.

Métrica	Valor
λ utilizado	0.070548
Datos usados	1200
ECM de ajuste	1.000033
Genes seleccionados	96 de 5000
Genes descartados	4904 de 5000

Punto 7 — Trazas de coeficientes

Se graficaron las trazas de los coeficientes del modelo Lasso en función de λ para los 1200 datos.

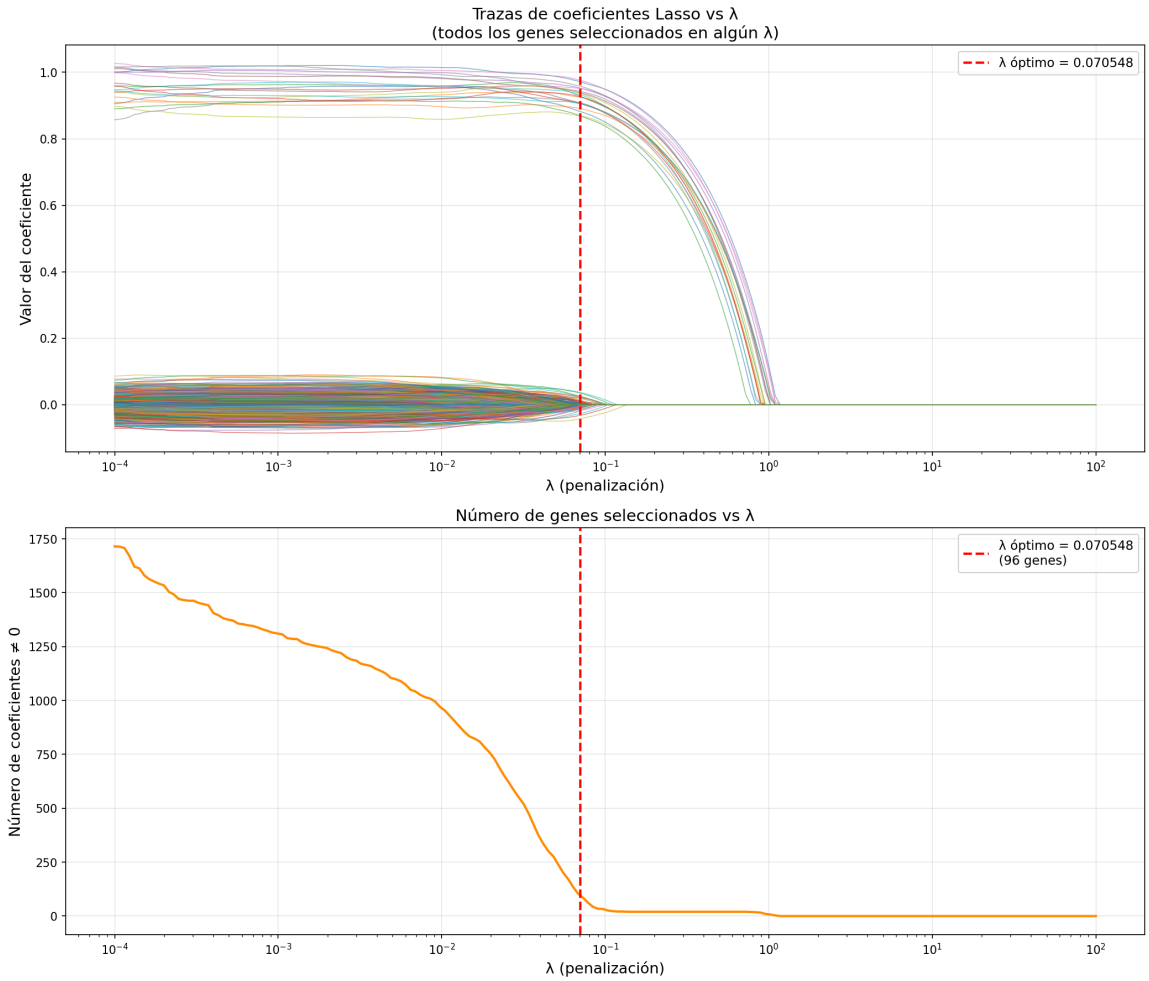

Figure 3: Trazas de coeficientes

Observaciones: - A medida que λ aumenta, los coeficientes se reducen progresivamente hacia cero (regularización L1). - Con λ muy pequeño se obtiene un modelo complejo; con λ muy grande, un modelo nulo. - En λ óptimo = 0.070548, se seleccionan 96 genes que balancean ajuste y parsimonia.

Punto 8 — Conclusiones generales

El estudio buscaba identificar cuáles de los 5000 genes son relevantes para predecir la efectividad de un tratamiento anticáncer en 1200 líneas celulares. Dado que p > n, se confirmó multicolinealidad perfecta, lo que justificó el uso de métodos regularizados. Se compararon Ridge y Lasso mediante validación cruzada 10-fold sobre 1000 datos de entrenamiento, encontrando que Lasso (λ = 0.070548) superó significativamente a Ridge al reducir el ECM de prueba en un 91.78% mientras seleccionaba solo 117 genes frente a los 5000 que retiene Ridge.

Al reajustar el modelo Lasso con los 1200 datos completos, se seleccionaron 96 genes relevantes de los 5000 disponibles. Las trazas confirman que el λ óptimo logra un equilibrio ideal entre precisión

y simplicidad: los genes que resisten la penalización son los biomarcadores más determinantes para el tratamiento.

En conclusión, Lasso demostró ser una gran herramienta para esté problema de alta dimensionalidad.

Reproducibilidad

```
pip install -r requirements.txt
python taller1.py
```

Semilla global: `2026`